



ĐẠI HỌC ĐÀ NẴNG

**TRƯỜNG ĐẠI HỌC BÁCH KHOA**

D  
BACH KHOA

N  
A  
N  
G

# TOÁN ỨNG DỤNG CÔNG NGHỆ THÔNG TIN



**Khoa Công Nghệ Thông Tin**

TS. Nguyễn Văn Hiệu

# Chuyên đề tối ưu hóa

## Bài 1: Gradient Descent

# Nội dung


1. Giới thiệu
2. Gradient descent cho hàm một biến
3. Gradient descent cho hàm nhiều biến
4. Phương pháp khắc phục hạn chế của Gradient descent
5. Các biến thể của Gradient descent
6. Bài tập

# Giới thiệu

## Bài toán tối ưu:

- Tìm giá trị lớn nhất hoặc nhỏ nhất của hàm số
- Bài toán có nhiều ứng dụng, đặc biệt ngành khoa học máy tính

## Ví dụ



## Một số vấn đề:

- $x^*$  là nghiệm cục bộ thì  $f'(x^*) = 0$
- Bên trái  $x^*$ :  $f'(x^*) < 0$ ; Bên phải  $x^*$ :  $f'(x^*) > 0$ ; tại  $x^*$ :  $f'(x^*) = 0$

# Giới thiệu

- Tìm nghiệm tối ưu toàn cục của hàm số:
    - Thường khó khăn hoặc không thể
    - Tìm nghiệm tối ưu cục bộ
  - Tìm nghiệm tối ưu cục bộ của hàm số:
    - Đạo hàm của hàm số đó phải bằng 0.
    - Khó khăn với bài toán với dữ liệu lớn hoặc chiều dữ liệu lớn
  - Hướng tiếp cận
    - Xuất phát từ một điểm ( xem gần với nghiệm bài toán)
    - Dùng phương pháp lặp để dịch chuyển điểm đó đến nghiệm cần tìm
- ⇒ Phương pháp Gradient descent

# Gradient descent cho hàm một biến

Xem ví dụ trước

- Nếu  $f'(x_t) > 0$ , thì  $x_t$  nằm bên phải  $x^*$ . Cần dịch chuyển sang trái

$$x_{t+1} = x_t + \Delta = x_t - \alpha \cdot f'(x_t)$$


- Nếu  $f'(x_t) < 0$ , thì  $x_t$  nằm bên trái  $x^*$ . Cần dịch chuyển sang phải

$$x_{t+1} = x_t + \Delta = x_t - \alpha \cdot f'(x_t)$$

- Thuật toán Gradient descent:

- Dự đoán một điểm khởi tạo  $x_t = x_0$
- Cập nhật  $x_t$  đến đạt đến kết quả chấp nhận

$$x_t := x_t - \alpha f'(x_t)$$



- Khái niệm “Gradient descent” chính dấu “-”: ngược hướng đằm hàm

# Gradient Descent cho hàm một biến(tiếp)


- Ví dụ tối ưu hàm số  $f(x) = x^2 + 5 \cdot \sin(x)$
- Khó khăn:  $f'(x) = 2 \cdot x + 5 \cdot \cos(x) = 0$
- Gradient descent: cho điểm  $x_t = x_0$  và cập nhật

$$x_t := x_t - \alpha(2 \cdot x + 5 \cdot \cos(x))$$

- Demo:



```

11 def myGD1(alpha, x0, gra = 1e-3, loop = 1000):
12     x = [x0]
13     for it in range(loop):
14         x_new = x[-1] - alpha*grad(x[-1])
15         if abs(grad(x_new)) < gra:
16             break
17         x.append(x_new)
18     return (x, it)
    
```



# Gradient Descent cho hàm một biến(tiếp)

- Điều kiện dừng của Gradient Descent
  - Giới hạn số bước lặp
  - So sánh giá trị hàm của nghiệm tại 2 lần cấp nhật
  - Kiểm tra giá trị tuyệt đối của Gradient
- Tốc độ hội tụ của Gradient Descent:
  - Phụ thuộc vào điểm khởi tạo
  - Phụ thuộc vào chỉ số Alpha





# Gradient Descent cho hàm đa biến

- Bài toán:
  - Tối ưu cho hàm  $f(\theta), \theta = (\theta_0, \theta_1, \dots, \theta_n)^T$
- Đạo hàm tại điểm  $\theta$ :  $\Delta_{\theta}f(\theta)$
- Thuật toán (tương tự hàm một biến)
  - Dự đoán một điểm khởi tạo  $\theta$
  - Cập nhật  $\theta$  đến khi nhận được kết quả chấp nhận được

$$\theta = \theta - \alpha \cdot \Delta_{\theta}f(\theta)$$

# Gradient Descent cho hàm đa biến(tiếp)

- Bài toán Linear Regression ( nhắc lại)
- Hàm mất mát

$$\begin{aligned} L(w) &= \frac{1}{2N} \sum_{i=1}^N \left( \bar{X}^{(i)} \cdot w - y^{(i)} \right)^2 \\ &= \frac{1}{2N} \left\| \bar{X} \cdot w - y \right\|_2^2 \end{aligned}$$

- Các ký hiệu:

$$y = \begin{pmatrix} y_1 \\ \vdots \\ y_N \end{pmatrix}, w = \begin{pmatrix} w_0 \\ \vdots \\ w_n \end{pmatrix}, \bar{X} = \begin{pmatrix} 1 & x_1^{(1)} & \dots & x_n^{(1)} \\ 1 & x_1^{(2)} & \dots & x_n^{(2)} \\ \vdots & \vdots & \dots & \vdots \\ 1 & x_1^{(N)} & \dots & x_n^{(N)} \end{pmatrix}$$

- Đạo hàm:

$$\Delta_w L(w) = \frac{1}{N} \bar{X}^T (\bar{X} \cdot w - y)$$

# Gradient Descent cho hàm đa biến(tiếp)

- Phương pháp truyền thống

$$\Delta_w L(w) = \frac{1}{N} \bar{X}^T (\bar{X}.w - y) = 0$$

$$\implies w = (\bar{X}^T \bar{X})^{-1} \bar{X}^T y$$

- Vấn đề khó khăn
  - N và n lớn
  - ...

$\Rightarrow$  Sử dụng Gradient descent


# Gradient Descent cho hàm đa biến(tiếp)

- Cài đặt Gradient descent


```
5 def grad(w):
6     N = Xbar.shape[0]
7     return 1/N * Xbar.T.dot(Xbar.dot(w) - y)
8
9 def l(w):
10    N = Xbar.shape[0]
11    return .5/N*np.linalg.norm(Xbar.dot(w)-y, 2)**2
12
13 def myGradientDescent(w_init, grad, alpha, loop = 1000, esilon = 1e-4):
14    w = [w_init]
15    for i in range(loop):
16        w_new = w[-1] - alpha*grad(w[-1])
17        if np.linalg.norm(grad(w_new))/len(w_new) < esilon:
18            break
19        w.append(w_new)
20    return (w, i)
```

# Gradient descent với hàm đa biến(tiếp)

- Điểm xét sẽ lần từ từ xuống hố và dừng lại ở đáy hố



- Tùy thuộc vào chọn điểm ban đầu mà kết quả có thể khác nhau




# Phương pháp khắc phục Gradient Descent

- Gradient Descent với Momentum
- Nesterov Accelerated Gradient (NAG)

# Gradient Descent với Momentum(đà)

- Vấn đề



- B có vận tốc đủ lớn khi di chuyển đến D, và theo đà sẽ di chuyển sang bên trái. Nếu vận tốc lớn hơn nữa thì sẽ di chuyển đến E và dừng ở C



# Gradient Descent với Momentum(đà)

- Thuật toán:
  - Dự đoán một điểm khởi tạo và vận tốc ban đầu

$$\theta_0 ; v_0$$

- Cập nhật đến đạt kết quả chấp nhận

$$\theta := \theta - v_t$$

- $v_t$  là vận tốc vật lý:
  - Thông tin về độ dốc (tức đạo hàm - gradient)
  - Thông tin về đà (tức vận tốc của  $v_{t-1}$  - momentum)



$$v_t = \beta \cdot v_{t-1} + \alpha \cdot \Delta_{\theta} J(\theta)$$



# Gradient Descent với Momentum(đà)

- Ví dụ:

$$f(x) = x^2 + 10.\sin(x), \quad x_0 = 5, \quad \alpha = 0.1$$




- Demo

```
13 def GD_momentum(theta_init, alpha=0.1, beta=0.9):
14     theta = [theta_init]
15     v_old = np.zeros_like(theta_init)
16     for it in range(1000):
17         v_new = beta*v_old + alpha*grad(theta[-1])
18         theta_new = theta[-1] - v_new
19         theta.append(theta_new)
20         v_old = v_new
21     return (theta,it)
```

# Nesterov Accelerated Gradient (NAG)

- Gradient Descent với Momentum
  - Giúp trượt quá điểm cực bộ
  - Hội tụ rất chậm khi về đích
- Phương pháp NAG
  - Dự đoán một điểm khởi tạo và vận tốc ban đầu  
 $\theta_0 ; v_0$
  - Cập nhật đến đạt kết quả chấp nhận



$$\theta := \theta - v_t$$

$$v_t = \beta \cdot v_{t-1} + \alpha \cdot \Delta_{\theta} J(\theta - \beta \cdot v_{t-1})$$

# Các biến thể Gradient Descent

## Batch Gradient descent

- Mỗi vòng lặp, dùng tất cả dữ liệu để tính gradient
- 1 Epoch: mỗi lần duyệt qua tất cả dữ liệu
- Khó khăn:
  - Dữ liệu huấn luyện quá lớn ( như facebook )
  - Online Learning: dữ liệu cập nhật liên tục

- Ví dụ

$$\begin{aligned} L(w) &= \frac{1}{2N} \sum_{i=1}^N \left( \bar{X}^{(i)} \cdot w - y^{(i)} \right)^2 \\ &= \frac{1}{2N} \left\| \bar{X} \cdot w - y \right\|_2^2 \end{aligned}$$

$$\Delta_w L(w) = \frac{1}{N} \bar{X}^T (\bar{X} \cdot w - y)$$

# Các biến thể Gradient Descent

## Stochastic Gradient descent

- Mỗi vòng lặp, dùng một mẫu dữ liệu để tính gradient
- Stochastic gradient descent có N lần cập nhật dữ liệu là 1 epoch
- Quy tắc cập nhật SGD:

$$\theta = \theta - \alpha \cdot \Delta_{\theta} J(\theta, x^{(i)}, y^{(i)})$$

$$(x^{(i)}, y^{(i)})$$

cặp dữ liệu (input, label)

$$\begin{aligned} L(w, \bar{X}^{(i)}, y^{(i)}) &= \frac{1}{2} \left( \bar{X}^{(i)} \cdot w - y^{(i)} \right)^2 \\ &= \frac{1}{2} \left\| \bar{X}^{(i)} \cdot w - y^{(i)} \right\|_2^2 \end{aligned}$$

$$\Delta_w L(w, \bar{X}^{(i)}, y^{(i)}) = \bar{X}^{(i)T} \left( \bar{X}^{(i)} w - y^{(i)} \right)$$

# Các biến thể Gradient Descent

## Mini\_batch Gradient descent

- Mini-batch gradient descent: mỗi vòng lặp, dùng một số lượng nhỏ  $k$  mẫu dữ liệu để tính gradient. Con số  $k$  được gọi là batch size
- Mini-batch - sử dụng lượng dữ liệu  $k > 1$  và nhỏ  $k < N$
- Xáo trộn dữ liệu trước lúc chia Mini-batch
- Quy tắc cập nhật Mini-batch GD:

$$\theta = \theta - \alpha \cdot \Delta_{\theta} J(\theta, x_{i:i+n}, y_{i:i+n})$$

- Trong thuật ngữ hiện đại, Stochastic gradient descent và Mini-batch gradient descent là như nhau: mỗi vòng lặp dùng  $k$  mẫu,  $k$  có thể là 1.

# Bài tập 1

Cài đặt thuật toán Stochastic Gradient descent cho bài toán Linear Regression

D  
BACH KHOA

N  
A  
N  
G

# Bài tập 2

Cài đặt thuật toán Mini Batch Gradient descent cho bài toán Linear Regression

D  
BACH KHOA

N  
A  
N  
G

# Bài tập 3

Cài đặt thuật toán Gradient descent cho bài toán MF

D  
BACH KHOA

N  
A  
N  
G



# Tài liệu

1. <https://runder.io/optimizing-gradient-descent/index.html#stochasticgradientdescent>
2. [Gradient Descen - Andrew Ng](#)

D  
BACH KHOA

N  
A  
N  
G



***Cám Ơn!***

# Chuyên đề tối ưu hóa

## Bài 2: Phương pháp Lagrange

# Phương pháp Lagrange

- Bài toán

$$\begin{cases} f(x) \rightarrow \min(/max) \\ g_i(x) = b_i, i = 1, \dots, m \\ x \in R^n \end{cases}$$

- Bước 1: Lập hàm Lagrange

$$L(x, \lambda) = f(x) + \sum_{i=1}^m \lambda_i [b_i - g_i(x)]$$

- Bước 2: Giải hệ phương trình

$$0 = \frac{dL}{dx_j} = \frac{df}{dx_j} - \sum_{i=1}^m \lambda_i \frac{dg_i}{dx_j}, j = 1, \dots, n$$

$$0 = \frac{dL}{d\lambda_j} = b_j - g_j(x), j = 1, \dots, m$$

# Phương pháp Lagrange

- Bước 3: từ tập điểm cực trị của  $L$ 
  - $d^2L > 0$ , thì cực trị của  $L$  là điểm cực tiểu
  - $d^2L < 0$ , thì cực trị của  $L$  là điểm cực đại

***Cám Ơn!***